

项 目 文 档

基于线性分析和随机森林的二手房房价影响因素分析

姓 名： 彭 思 淇

指 导 教 师 姓 名： 韦 小 多

专 业 名 称： 数据科学与大数据技术

二〇二六年 四 月

目录

一、 项目背景	3
二、 数据说明	3
1. 数据来源	3
2. 数据特征及类型	4
三、 相关理论基础	5
1. 技术栈概览	5
2. 技术选型理由	6
3. 多元线性回归	6
4. 随机森林	7
四、 数据预处理	8
1. 整体流程概览	8
2. 处理结果概要	8
3. 数据预处理	8
4. 描述性分析	10
五、 贵阳市二手房价格的评估模型构建	16
1. 建模步骤流程图	16
2. 线性回归算法	16
3. 随机森林模型	18
4. 贵阳市二手房成交价格影响因素分析	22
六、 遇到的问题	23
七、 改进方向	24
1. 数据源层面	24
2. 清洗与处理层面	24
3. 可视化与交互层面	25
4. 建模预测层面	25
5. 项目分享与协作	25
附录 参考文献	26

一、项目背景

本项目用于数据处理与业务分析，核心目标是通过对二手房数据的清洗与预处理，掌握数据清洗的基本流程与方法，并基于数据处理与建模得到的结果进行二手房房价影响因素的分析与预测。数据来源于 Kaggle 平台上的公开数据集，该数据集包含了贵阳市各区域的二手房挂牌信息，涵盖价格、面积、户型、所在楼层、建筑年份等字段。原始数据存在较多缺失值、异常值、重复记录以及格式不统一等问题，非常适合用于数据清洗实践。通过本项目的操作，学习者可以熟悉缺失值处理、异常值检测、数据格式转换、重复记录剔除等常用技术，并为后续的数据分析和可视化奠定基础。同时，在清洗过程中也能初步观察贵阳不同区域二手房的价格分布、面积特征等市场特点，加深对数据预处理重要性的理解，进一步了解数据处理与分析对业务的重要性，在此基础上提升业务分析能力。

二、数据说明

1. 数据来源

本项目使用的二手房交易数据来源于 Kaggle 公开数据集（数据集名称：Second-hand-housing-raw，作者/上传者：dataml999，最后更新时间：2025 年 11 月）。该数据集由爬虫采集自贵阳本地房产信息平台，涵盖了贵阳市主要城区的二手房挂牌信息，适合用于数据清洗与分析实践。

原始数据集共包含 20059 条记录，涉及 31 个字段。数据涵盖的区域包括观山湖区、南明区、云岩区、花溪区、白云区、乌当区等，时间范围为 2024 年 1 月至 2025 年 10 月。

2. 数据特征及类型

下表列出了数据集中用到的各字段的名称及类型：

字段名	类型	字段名	类型
房源 ID	object	房屋朝向	object
地址	object	建筑结构	object
价格(万)	float64	装修情况	object
单价	object	梯户比例	object
客厅	object	配备电梯	object
卧室 A	object	产权年限	object
卧室 B	object	挂牌时间	object
厨房	object	交易权属	object
卫生间	object	上次交易	object
阳台	object	房屋用途	object
房屋户型	object	房屋年限	object
所在楼层	object	产权所属	object
建筑面积	object	抵押信息	object
户型结构	object	房本备件	object
套内面积	object	房源描述	object
建筑类型	object		

表 1 各字段的名称及类型

三、相关理论基础

1. 技术栈概览

数据处理过程以 Kaggle 平台为基础，在 Kaggle Notebook 中完成数据清洗和初步分析。清洗过程主要使用 Pandas 进行缺失值处理和格式转换，配合 NumPy 进行数值计算。可视化部分使用 Excel 制作最终图表。代码版本管理使用 Git，项目文档与项目代码将发布在 GitHub 和 Kaggle 平台。

类别	技术/工具	版本	用途说明
编程语言	Python	3.10	核心编程语言，用于数据清洗、转换和初步分析。
数据处理与分析	Pandas	1.5.3	数据加载、缺失值处理、数据筛选、聚合等清洗工作。
	NumPy	1.23.5	数值计算支持，配合 Pandas 进行数组运算。
数据可视化	Microsoft Excel	2021	利用 Excel 制作图表（柱状图、折线图、饼图等），进行最终可视化呈现。
开发环境	Kaggle Notebooks	-	云端交互式开发环境，记录数据清洗的全过程，并利用 Kaggle 的免费计算资源运行代码。
版本控制与发布	Git	2.40	本地代码版本管理，追踪修改记录。
	GitHub	-	代码托管平台，用于分享项目、备份代码，并与他人协作。
文档与协作	Markdown	-	在 Kaggle Notebook 中撰写说明文档，使分析过程清晰可读。

表 2 详细技术栈清单

2. 技术选型理由

本项目的技术选型主要基于以下几点考虑：

- (1) Kaggle Notebooks 作为开发环境，看重它的便捷性和兼容性——无需本地配置，开机即用，自带主流数据科学库，且后续能直接在 Kaggle 平台分享代码，方便复现。
- (2) Excel 用于可视化，是因为它使用场景广，能一边查看数据表格一边调整图表，操作直观，适合快速制作最终需要呈现的统计图。
- (3) GitHub 作为代码托管平台，一方面受其丰富的开源资源启发，另一方面也希望将自己的项目开源，为社区贡献一份力量，同时方便他人查阅和复用。

3. 多元线性回归

多元回归分析常用于房地产批量评估，包括线性和非线性形式。最经典的是线性回归，尤其是效用函数或特征价值模型。该方法基于房地产的空间和非空间特征属性与市场供给关系，利用计量经济学构建估价模型，分析特征与价格间的内在关系，得出评估价值。在批量评估中，将房价作为因变量，宏观因素和房屋特征作为自变量，如商圈距离、经济水平、建筑年代、楼层等。通过预设、量化影响房价的特征并确定系数，模型可预测类似样本的价格。构建模型时需考虑多种因素、特征量化、回归拟合、模型检验和结果分析等，多元线性回归模型构建如下：

（1）特征变量选择。按照模型的适用范围选择特征变量，主要考虑影响房价的特征因素，包括房屋的区位特征、建筑特征和邻里环境特征因素等。

（2）特征变量数据转化。特征变量的量化受多方面的影响，主要包括连续变量、离散变量等，连续变量一般为数值型，取实际值即可，离散变量数据表现一般为类别，可按不同等级赋值或者采取虚拟变量量化法。

（3）模型方程选择。适合的模型能够正确的表达出自变量与因变量之间的关系，如果选择模型出现误差，将导致结果也会出现错误估计。特征价格模型的一般形式为：

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \dots + \beta_n x_n + \varepsilon$$

其中：

y ：二手房总价（万元）

β_0 ：截距项，即所有特征取值为 0 时的房价

x_n ：第 n 个特征（如建筑面积，房间数，区域等虚拟变量）

β_n ：第 n 个特征对应的回归系数，表示在其他特征不变的情况下，该特征变化一个单位时房价的平均变化量

ε ：随机误差项，代表模型未能捕捉的随机因素

模型通过最小二乘法估计系数，及最小化残差平方和：

$$\min \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

其中 $\hat{y}_i$ 为第 i 个样本的预测值

4. 随机森林

随机森林（Random Forest）是一种集成学习方法，通过对多棵决策树集成来完成分类或回归任务，该算法由 Leo Breiman 和 Adele Cutler 于 2001 年首次提出。随机森林是一种集成学习模型，由多颗决策树基模型构建。每棵树都依赖于从独立同分布的随机向量数据集的取值。在构建随机森林模型的过程中，随着决策树数量的递增，模型的泛化性能逐渐呈现出一种饱和趋势，最终趋于一个稳定的极限值。泛化误差的产生深受森林内各决策树强度及其相互关联性的影响。随机森林选择随机选择特征进行节点划分的方法具有一定优势，因为这种方法在处理噪声方面表现出强大的鲁棒性。通过使用随机选择特征进行节点划分，随机森林能够有效降低错误率，并增强对噪声的抵抗能力。此外，通过内部估计，随机森林能够监测错误率、强度和相关性等指标，展示了在增加划分特征数时系统的响应。

四、数据预处理

1. 整体流程概览

本项目的处理流程遵循数据清洗的标准步骤，从数据加载、列筛选、缺失值处理、数据类型转换、特征提取到最终的数据导出与分析。所有操作均在 Kaggle Notebook 中完成，主要使用 Pandas 包 进行数据操作。



图 1 数据预处理整体概览流程图

2. 处理结果概要

- ◆ 数据规模：清洗后保留 20059 条记录，27 个字段（原始 31 个，删除 12 个，新增 8 个）。
- ◆ 缺失值：全部处理完毕，无缺失。
- ◆ 数据类型：所有数值字段均为 float 或 int，日期字段已转换，分类字段为 object。
- ◆ 新增特征：房间数、客厅数、厨房数、卫生间数、所处楼层、楼层数、所处区域、小区。

3. 数据预处理

1) 数据的加载与无关列删除

首先导入初始数据，通过 `df.columns` 查看所有字段。根据分析需求，删除描述性过强的文本列（如“客厅”“卧室 A”等）和冗余标识列（如“房源 ID”），保留核心分析字段，以便后续进行数据处理，避免非预期内的噪声数据干扰数据清洗过程。

2) 数据预处理与特征提取

处理缺失值和数据类型转换时，先检查价格字段，由于缺失值不多，直接选择用均值补充。单价字段原本是文本格式，带着“元/平米”和各种括号和空格，把这些字符清洗后转为数值，空缺部分同样用均值填充。建筑面积也用类似方式处理，去掉“m²”“平米”等文字单位描述后转成数字，缺失值用均值填充。

接下来从原始文本里提取有用信息。计算房屋户型频率，将出现频率最高的“3室2厅1厨2卫”填充进 null，再把房屋户型的“室|厅|厨|卫”提取出来并创建新的列：房间数，客厅数，厨房数，卫生间数四个整数特征，删除“房屋户型”这一字段。“所在楼层”字段的处理也类似，查看所在楼层有多少缺失值，同样的方法处理所在楼层和建筑面积，通过字符串替换统一格式，再分割提取分类特征（低/中/高）和数值特征（总楼层数），并且新增两列：所处楼层和楼层数。地址信息字段用斜杠分割，拆出“所处区域”和“小区”两列。

清洗后的数据类型见下表，加粗字段为修改后的字段。

字段名	类型	字段名	类型
地址	object	建筑结构	object
价格(万)	float64	装修情况	object
单价	float64	梯户比例	object
房屋户型	object	配备电梯	object
所在楼层	object	产权年限	object
建筑面积	float64	挂牌时间	object
户型结构	object	交易权属	object
套内面积	object	房屋用途	object
建筑类型	object	产权所属	object
房屋朝向	object	抵押信息	object
房间数	int	客厅数	int
厨房数	int	卫生间数	int

表 3 清洗后的字段

最后处理剩下的文本字段。将描述性的文本列，比如装修情况、建筑结构等字段，由于其缺失值不多，直接按前一条记录的内容往前填充，这样能快速补上。

经过以上几步数据类型标准化处理的步骤，数据格式统一，便于后续的数据建模与分析总结。

3) 数据质量检查与初步统计

做完前面几步清洗和特征提取后，接着对数据做了整体检查。先用 `describe()` 看了一下数值字段的分布，包括均值、标准差和分位数，发现价格、面积这些字段存在一些特别高或特别低的值，和常规情况对不上，初步估计是极端样本。然后利用 `groupby()` 又做了分组聚合，按区域、装修这些类别统计平均价格，查询不同组之间差异是否正常，验证数据的合理性，结果和直观感受大体吻合。最后利用数据透视表，把多维度的汇总结果存保存为外部文件，方便后续拿到 Excel 里进行数据可视化。这一步主要是为了确认数据清洗效果，同时也对数据整体情况有了更具体的了解。

4. 描述性分析

1) 清洗前后数据对比与概览

指标	清洗前	清洗后
记录数	20059 条	20059 条（保留全部记录）
字段数	31 个	27 个（删除 12 列，新增 8 列）
缺失值	多处字段存在缺失	全部处理完毕，无缺失
数据类型	多为 object	数值字段统一为 float/int，日期字段转换完成
新增特征	无	房间数、客厅数、厨房数、卫生间数、所处楼层、楼层数、所处区域、小区

清洗完成后，数据规模为 20059 条记录，共 27 个字段。所有字段均无缺失值，内存占用约 4.1 MB。如下表所示，数据类型分布为：float64（3 个）、int64（4 个）、object（20 个）。数值字段包括“价格(万)”“单价”“建筑面积”及提取的房间数、客厅数、厨房数、卫生间数；文本字段涵盖地址、所在楼层、户型结构等原始信息及新增的“所处楼层”“所处区域”“小区”等。

字段名	非空数量	数据类型
地址	20059 无空数	object
价格（万）	20059 无空数	float64
单价	20059 无空数	float64
所在楼层	20059 无空数	object
建筑面积	20059 无空数	float64
户型结构	20059 无空数	object
套内面积	20059 无空数	object
建筑类型	20059 无空数	object
房屋朝向	20059 无空数	object
建筑结构	20059 无空数	object
装修情况	20059 无空数	object
梯户比例	20059 无空数	object
配备电梯	20059 无空数	object
产权年限	20059 无空数	object
挂牌时间	20059 无空数	object
交易权属	20059 无空数	object
房屋用途	20059 无空数	object
产权所属	20059 无空数	object
抵押信息	20059 无空数	object
房间数	20059 无空数	int64
客厅数	20059 无空数	int64
厨房数	20059 无空数	int64
卫生间数	20059 无空数	int64
所处楼层	20059 无空数	object
楼层数	20059 无空数	object

所处区域	20059 无空数	object
小区	20059 无空数	object

表 4 数据清洗结果一览表

	价格(万)	单价	建筑面积	房间数	客厅数	厨房数	卫生间数
count	20059.000000	20059.000000	20059.000000	20059.000000	20059.000000	20059.000000	20059.000000
mean	127.111157	10508.351463	116.287305	2.897801	1.781096	0.997109	1.570367
std	118.355419	3179.527288	77.197176	1.057347	0.517892	0.198939	0.693597
min	1.800000	3847.000000	10.000000	0.000000	0.000000	0.000000	0.000000
25%	80.000000	8609.000000	83.000000	2.000000	2.000000	1.000000	1.000000
50%	108.000000	9767.000000	109.670000	3.000000	2.000000	1.000000	1.000000
75%	142.000000	11539.000000	135.965000	3.000000	2.000000	1.000000	2.000000
max	9000.000000	88603.000000	5963.000000	20.000000	9.000000	9.000000	9.000000

图 2 数据比对表

从清洗后数据的描述性统计来看，整体分布比较合理，但存在一些需要留意的异常情况。

价格方面，样本总量 20059 条，均值 127.11 万元，中位数 108 万元，说明大部分房源集中在 80-142 万元这个区间（上下四分位数分别为 80 万和 142 万）。但最小值 1.8 万元、最大值 9000 万元这两头差异太大，标准差达到 118.36 万元，反映出数据存在明显的极端值。1.8 万元的极低值可能是车位或非住宅类房产，9000 万元的高值大概率是别墅或录入错误，这类样本对整体统计指标影响较大。

单价和面积的数据特征也类似。单价均值 10508 元/m²，和贵阳市场主流价格匹配，中位数 9767 元/m²、75%分位数 11539 元/m²的分布也比较集中。但最大值 88603 元/m²明显偏高，对应那些面积小但总价高的特殊房源。建筑面积均值 116.3 m²，中位数 109.67 m²，符合常见三房两厅的面积段，但最大值 5963 m²这种明显超出住宅范畴，可能是商业性质的房产或采集错误。

户型特征数据比较干净。房间数、客厅数、厨房数、卫生间数的统计值都落在常规区间，比如房间数中位数 3、卫生间数中位数 1，和三室两厅一厨两卫的主流户型吻合。厨房数均值 0.997，卫生间数均值 1.01，说明绝大多数房源配置标准。

整体来看，数据完整性没问题，核心字段的集中趋势和实际情况对得上，就

是部分极端值得单独考虑。后续分析时要么把这些异常样本剔除，要么单独讨论它们的影响。

2) 可视化图表



图 3 贵阳市各区域二手房均价对比

本图表展示了贵阳市主要城区的二手房平均总价（单位：万元）。数据基于清洗后的数据集，通过 Excel 数据透视表计算各区域“价格(万)”的平均值，并生成柱状图。从各区域二手房均价来看，价格梯队较为分明。乌当区以 208.39 万元的平均总价位居首位，明显高于其他区域；观山湖区（166.68 万元）与花溪区（153.91 万元）处于第二梯队；南明区（130.72 万元）、云岩区（121.39 万元）、白云区（106.43 万元）居中；清镇市（73.96 万元）和开阳县（70.00 万元）则处于价格低位。

这一分布与各区域的功能定位密切相关。乌当区作为新兴高端住宅聚集区，样本中别墅和大户型占比较高，推高了整体均价；观山湖区是政务与金融中心，房价长期处于较高水平；花溪区以生态宜居为特色，同样维持较高价位；而清镇市、开阳县因距离主城区较远，价格相对较低，符合市场规律。值得注意的是，花溪区均价超过南明、云岩等传统核心区，可能与样本中高端楼盘占比较高有关，具体原因还需结合户型、面积等因素进一步分析。该对比不仅为购房者提供了价格参考，也为后续建模中“区域”这一特征提供了量化依据。




图 4 不同装修情况对价格的影响

本图表比较了不同装修程度（简装、精装、毛坯、其他）的二手房平均总价（单位：万元）。通过数据透视表计算各装修类别下“价格(万)”的均值，并生成柱状图。

主要发现：

毛坯房均价最高（160.72 万元）：这一结果与常规认知（精装>毛坯）相反，初步分析可能原因包括：毛坯房中包含大量大面积户型或别墅，总价本身较高；毛坯房可能集中在高价位区域（如乌当、观山湖），区域效应掩盖了装修本身的影响；数据中“毛坯”样本可能存在极端高值，需进一步核实；精装房均价 129.64 万元：低于毛坯，但高于简装（107.28 万元）和其他（113.44 万元），符合“精装溢价”的一般规律；简装房价格最低：简装房多为老旧小区或快速出手房源，价格相对实惠。

该结果提示我们，装修情况对价格的影响可能受到区域、面积等其他因素的干扰，不能简单独立分析。后续可通过多维度交叉分析（如控制区域后再对比装修均价）或建立回归模型，剥离其他因素后评估装修的真实贡献。尽管结果与预期有出入，但揭示了数据中可能存在的混杂因素，为更深入的特征工程和建模分析提供了线索。




图 5 面积与总价散点图

说明：本图表以建筑面积（ m^2 ）为横轴，总价（万元）为纵轴，绘制了二手房面积与总价的散点图。数据来源于清洗后的数据集，共包含 101 个样本点（随机抽样 101 个表格中的样本），用于探究两者之间的相关关系。

从面积与总价的散点图来看，两者之间存在明显的正相关关系。随着建筑面积增加，房屋总价整体呈上升趋势，符合“面积越大总价越高”的市场规律。从样本分布来看，大部分点集中在两个区域：一是面积 100-120 m^2 、总价 300-400 万元的区间，样本密度最高，对应贵阳市主流的刚需和改善型户型；二是面积 140-150 m^2 、总价 400 万元左右，对应大户型或高端改善型房源。此外也有一些离散点值得留意：少数面积较小（约 100 m^2 ）但总价达到 400 万元的房源，可能位于核心区域（如观山湖区）或拥有精装修、优质学区等附加价值；另有一些面积较大（约 140 m^2 ）但总价仅 300 万元的房源，可能位于价格较低的区域（如白云区、花溪区）或存在楼层、朝向等不利因素。该散点图直观验证了面积与价格的正相关关系，为房价估算提供了基础参考，同时也提示区域、装修、楼层等因素同样对价格有显著影响，需要在后续多因素分析中加以考虑。

所处区域	平均值项: 价格(万)
白云区	¥ 106.43
观山湖区	¥ 166.68
花溪区	¥ 153.91
开阳县	¥ 70.00
南明区	¥ 130.72
清镇市	¥ 73.96
乌当区	¥ 208.39
云岩区	¥ 121.39
总计	¥ 137.38

图 6 数据透视表实例（部分）

说明：已导出为 AAAA.csv，便于后续分析

五、贵阳市二手房价格的评估模型构建

1. 建模步骤流程图



图 7 建模步骤流程图

2. 线性回归算法

(1). 数据准备

使用清洗后的数据集（原始记录 20059 条，清洗后保留 27 个字段）。在建模前，对数值型特征进行强制类型转换，并用中位数填充缺失值（其中“楼层

数”填充了 1 个缺失值）。为了减少极端值对模型的影响，采用四分位距（3 倍 IQR）剔除价格过高或过低的异常样本。剔除后剩余 19489 条记录用于后续建模。

(2). 特征选择与编码

选取以下特征作为自变量：

数值特征：建筑面积、房间数、客厅数、厨房数、卫生间数、楼层数

分类特征：所处区域、装修情况、所处楼层

目标变量为“价格(万)”。

由于线性回归要求输入为数值型数据，对分类特征采用独热编码（One-Hot Encoding）转换为多个 0/1 虚拟变量。数值特征保持不变。最终参与建模的特征数量为原始特征经编码后得到的全部变量。

(3). 训练集与测试集划分

按 8:2 的比例随机划分训练集和测试集，固定随机种子以保证结果可复现。划分如下：

训练集：15591 条

测试集：3898 条

(4). 模型训练

使用 `sklearn.linear_model.LinearRegression` 在训练集上拟合线性回归模型。

从线性回归建模的结果来看，整个过程按步骤推进。原始数据共 20059 条、27 个字段，清洗数值列时发现“楼层数”有 1 个缺失值，用中位数补上。为了减少极端值对模型的影响，采用 3 倍 IQR 剔除价格过高或过低的异常样本，剔除后剩余 19489 条记录。按 8:2 划分训练集和测试集，得到训练集 15591 条、测试集 3898 条。

模型训练完成后，在测试集上进行评估：平均绝对误差（MAE）为 24.64 万元，说明预测值与真实值平均相差约 24.64 万元；均方根误差（RMSE）为 34.89 万元，对较大误差的惩罚更强；决定系数（ R^2 ）为 0.5656，意味着模型能够解释房价变异的 56.56%，拟合效果中等。

特征排名	特征名	系数
19	所处楼层	123.187055
13	所处区域_观山湖区	45.510048
7	所处区域_云岩区	25.993469
1	房间数	21.669892
4	卫生间数	19.819751
8	所处区域_南明区	16.920226
11	所处区域_白云区	12.848932
12	所处区域_花溪区	11.558418
6	所处区域_乌当区	11.075996
2	客厅数	4.882480

表 5 影响最大的前十个特征

(5). 模型评估

在测试集上计算以下指标：

平均绝对误差（MAE）：24.64 万元，表示预测值与真实值的平均差距约为 24.64 万元。

均方根误差（RMSE）：34.89 万元，对较大误差的惩罚更强，反映预测的稳定性。

决定系数（R²）：0.5656，表明模型可以解释房价总变异的 56.56%，拟合效果中等。

3. 随机森林模型

(1). 数据准备

与线性回归使用完全相同的数据集，以保证对比的公平性。原始数据 20059 条，清洗后保留 27 个字段。建模前对数值型特征强制类型转换并用中位数填充缺失值（其中“楼层数”填充了 1 个缺失值）。采用四分位距（3 倍 IQR）剔除价格过高或过低的极端样本，剔除后剩余 19489 条记录。

(2). 特征选择与编码

选取与线性回归相同的特征：

数值特征：建筑面积、房间数、客厅数、厨房数、卫生间数、楼层数

分类特征：所处区域、装修情况、所处楼层

目标变量为“价格(万)”。

为便于提取特征重要性并与线性回归对比，同样对分类变量进行独热编码，将每个类别转换为 0/1 虚拟变量。数值特征保持不变。

(3). 训练集与测试集划分

按 8:2 的比例随机划分训练集和测试集，固定随机种子。运行如下：

训练集：15591 条

测试集：3898 条

(4). 模型训练

使用 `sklearn.ensemble.RandomForestRegressor` 进行训练，主要参数设置：

树的数量 (`n_estimators`)：100

最大深度 (`max_depth`)：15（限制树深，防止过拟合）

内部节点再划分所需最小样本数 (`min_samples_split`)：10

叶子节点最少样本数 (`min_samples_leaf`)：5

随机种子 (`random_state`)：42

从随机森林建模的结果来看，整个过程与线性回归保持一致。原始数据共 20059 条、27 个字段，清洗数值列时同样发现“楼层数”有 1 个缺失值，用中位数补上。随后采用 3 倍 IQR 剔除价格过高或过低的异常样本，剔除后剩余 19489 条记录。按 8:2 划分训练集和测试集，训练集 15591 条，测试集 3898 条。

模型训练完成后，在测试集上评估：平均绝对误差 (MAE) 为 18.96 万元，均方根误差 (RMSE) 为 28.81 万元，决定系数 (R^2) 为 0.7037。与线性回归相比，MAE 降低了约 5.68 万元，RMSE 降低了约 6.08 万元， R^2 提升了约

0.1381，表明随机森林对房价的预测精度更高，拟合效果明显优于线性回归。

特征序号	特征	重要性
0	建筑面积	0.76394
5	楼层数	0.093074
13	所处区域_观山湖区	0.040481
7	所处区域_云岩区	0.011423
1	房间数	0.011342
18	装修情况_精装	0.009283
4	卫生间数	0.009016
21	所处楼层_低	0.007000
16	装修情况_毛坯	0.006833
17	装修情况_简装	0.006433

表 6 特征重要性前十

(5). 模型评估

在测试集上计算评估指标，结果如下：

MAE（平均绝对误差）：18.96 万元

表示预测值与真实值的平均差距约为 18.96 万元，优于线性回归的 24.64 万元。

RMSE（均方根误差）：28.81 万元

对较大误差的惩罚更强，同样低于线性回归的 34.89 万元。

R²（决定系数）：0.7037

表明模型可以解释房价总变异的 70.37%，拟合效果明显优于线性回归(0.5656)。

(6). 特征重要性解释

随机森林可以输出每个特征的重要性得分，其基于所有树中该特征在节点分裂时带来的不纯度（均方误差）减少量的平均值。得分越高，说明该特征对预测的贡献越大。

下表列出了重要性排名前 10 的特征：

特征	重要性	解释
建筑面积	0.7764	最重要的特征,说明建筑面积是决定房价的首要因素,超过 77% 的预测贡献来自于面积。
楼层数	0.0931	总楼层数对价格有显著影响,可能反映了高层住宅的视野、采光优势或低层的便利性。
所处区域_观山湖区	0.0405	区域虚拟变量中重要性最高,表明观山湖区作为政务金融中心的区位优势对房价有重要贡献。
所处区域_云岩区	0.0114	云岩区的区域效应也较为重要,但与观山湖区相比差距明显。
房间数	0.0113	房间数的重要性与云岩区相近,说明户型设计对价格有独立影响。
装修情况_精装	0.0093	精装修对房价有一定正面贡献,但重要性低于面积和区域。
卫生间数	0.0090	卫生间数量同样具有影响,但相对较弱。
所处楼层_低	0.0070	低楼层（相对于其他楼层）的重要性较低,说明楼层类型的影响有限。
装修情况_毛坯	0.0068	毛坯的重要性与精装接近,但毛坯本身可能多位于高价区域,其真实贡献需结合其他因素。
装修情况_简装	0.0064	简装修的重要性最低,表明装修对房价的边际影响较小。

几点观察：

- 建筑面积的绝对主导地位（0.7764）与市场常识一致，面积越大总价越高。
- 楼层数的重要性位列第二，说明总楼层高度本身（而非所处楼层）是重要因素，可能因为高层住宅的稀缺性或建筑类型差异。
- 区域特征中仅观山湖区进入前五，其他区域（如云岩、南明等）重要性较低，反映出观山湖区在贵阳二手房市场中的独特地位。
- 装修情况整体重要性偏低（合计约 0.0225），说明装修对房价的独立贡献有

限，其影响可能被面积和区域所吸收，这与描述性分析中“毛坯均价最高”但进入模型后重要性不高的现象吻合。

户型特征（房间数、卫生间数）具有一定重要性，但远低于面积，说明在面积固定的前提下，房间数量的边际效益有限。

(7). 模型对比与小结

与线性回归相比，随机森林在各项评估指标上均有显著提升：

MAE 从 24.64 万元降至 18.96 万元，降幅约 23%

RMSE 从 34.89 万元降至 28.81 万元，降幅约 17%

R^2 从 0.5656 提升至 0.7037，提高了 24%

这表明房价与特征之间的关系并非完全线性，存在复杂的交互和非线性模式，随机森林能更有效地捕捉这些模式，从而获得更高的预测精度。

特征重要性进一步印证了描述性分析中的关键发现：面积是第一决定因素，其次是区域（尤其是观山湖区）和楼层数，装修和具体楼层类型的影响相对有限。这一结论为购房决策和房产估值提供了量化依据：在贵阳市场，优先关注面积和地段，装修可视为次要因素。

4. 贵阳市二手房成交价格影响因素分析

建筑面积是最主要的影响因素。随机森林模型中，建筑面积的重要性达到 0.776，远超其他所有特征，说明房价高低首先取决于房屋大小。线性回归中，虽然建筑面积本身未进入系数前十，但房间数（系数 21.67）、卫生间数（19.82）等与面积高度相关的变量系数较大，间接反映了面积的主导作用。区域位置是第二个关键因素。观山湖区的区域虚拟变量在线性回归中系数高达 45.51，在随机森林中重要性 0.0405，均显著高于其他区域；云岩区、南明区等传统核心区也有一定溢价。这与描述性分析中观山湖区均价领先的结论一致，表明地段是房价的核心决定因素。

总楼层数和户型设计对价格有边际贡献，但影响弱于面积和区域。随机森林

中，楼层数（总楼层）的重要性为 0.093，在单个特征中排名第二；但若将各区域虚拟变量合并计算，区域整体的重要性仍高于楼层数。因此更准确的排序是：面积第一，区域第二，楼层数第三。房间数和卫生间数在线性回归中系数均超过 19 万元，在随机森林中重要性也进入前十，表明多居室、多卫生间配置能提升房屋价值，但贡献远不及面积。装修情况整体重要性偏低，随机森林中精装、毛坯、简装三项合计重要性仅 0.0225，线性回归中装修特征未进入系数前十。描述性分析中“毛坯房均价最高”的现象，在建模后被解释为毛坯房多集中于大户型或高价区域所致，控制面积和区域后装修本身溢价有限。

随机森林的预测精度（ $R^2=0.704$ ）明显优于线性回归（ $R^2=0.566$ ），说明房价与特征之间存在非线性关系和交互作用，单纯线性模型难以完全刻画。线性回归系数中“所处楼层_7122”一项系数异常偏高（123.19），提示数据中可能存在极少数特殊样本（如顶层复式或录入错误），但不影响整体结论。综合来看，贵阳二手房价格主要由面积和区域决定，楼层、户型、装修为次要因素。这一结论可为购房者提供参考：预算有限时优先考虑面积和地段，装修和具体楼层可适当让步。后续引入学区、交通等外部数据有望进一步提升模型解释力。

六、遇到的问题

问题类型	具体描述	解决方法
缺失值处理策略	部分字段（如“阳台”“上次交易”）缺失比例高，直接删除可能丢失信息，但保留又无法填充合理值。	根据字段含义决定：文本型描述字段（如“阳台”）填充“无”；时间型字段（如“上次交易”）缺失过多，直接删除列。
单价字段格式不一	“单价”字段包含“元/平米”文字，部分记录还带有空格或括号，直接转换报错。	先用 <code>str.replace()</code> 统一去除单位，再用 <code>astype(float)</code> 转换；若有转换失败则进一步检查异常格式。

“所在楼层”异常值	存在“未知(共 0 层)”等异常记录, 且部分格式不统一(如“低楼层/共 6 层”与“低层(共 6 层)”)。	先用 <code>str.replace()</code> 将所有异常统一替换为常见格式(如“中楼层(共 8 层)”), 再分割提取。
“地址”分割不一致	地址字段使用“/”分隔, 但部分记录分隔符数量不等, 导致提取时索引越界。	先检查分隔符数量, 对不足的补全; 提取后清洗空格, 并将空值替换为“其他区域”。
前向填充的适用性	使用 <code>ffill</code> 批量填充时, 若连续多条记录均缺失, 可能导致填充值偏离实际。	检查填充后的数据分布, 确认无异常; 对于关键字段(如价格)单独处理, 避免误填充。
编码问题导致导出乱码	导出 CSV 时中文显示乱码。	使用 <code>encoding='utf_8_sig'</code> 解决 Excel 打开乱码问题。

七、改进方向

1. 数据源层面

获取更多维度数据: 引入学区信息、地铁距离、周边商业配套等外部数据, 丰富分析维度。

补充时间序列: 获取多期数据, 分析房价随时间的变化趋势, 识别季节性波动。

扩大区域范围: 若可能, 加入贵州省其他城市数据, 进行跨区域对比。

2. 清洗与处理层面

优化异常值检测: 采用统计方法(如 `IQR`、`Z-score`)替代人工阈值, 更科学地识别异常。

文本挖掘深化：对“房源描述”字段进行 NLP 分析，提取装修风格、采光、税费等隐含特征。

自动化清洗脚本：将清洗流程封装为函数或脚本，便于复用和迁移到其他类似数据集。

3. 可视化与交互层面

Python 动态图表：使用 Plotly、Pyecharts 制作交互式图表，支持鼠标悬停查看详细信息。

仪表盘构建：利用 Tableau 或 Power BI 搭建可视化仪表盘，动态筛选区域、价格区间等。

地图可视化：基于区域坐标绘制房价热力图，直观展示价格空间分布。

4. 建模预测层面

模型解释性：使用 SHAP 值解释模型预测结果，分析各因素对房价的边际影响。

模型部署：将最优模型封装为轻量级 API（如 Flask + 简单前端），提供在线房价估算工具。

5. 项目分享与协作

完善 GitHub 仓库：补充详细 README，包含环境配置、数据说明、代码结构、复现步骤。

Kaggle Notebook 优化：增加 Markdown 注释，按章节划分，便于他人阅读和 fork。

撰写技术博客：将项目经验整理成文章，分享至知乎、简书等平台，与社区交流。

附录 参考文献

- [1] 吴祥龙.成都市二手房价格影响因素分析及预测[D].西南大学,2025.DOI:10.27684/d.cnki.gxndx.2025.001971.
- [2] 霍玉娇.基于单一与组合模型的二手房房价预测研究[D].中国地质大学(北京),2024.DOI:10.27493/d.cnki.gzdzy.2024.000002.
- [3] 全磊田.基于决策树的北京二手房价格预测及影响因素研究[D].北京工业大学,2024.DOI:10.26935/d.cnki.gbjgu.2024.000442.
- [4] 吴丹.基于机器学习的重庆市二手住宅房价批量评估研究[D].重庆理工大学,2024.DOI:10.27753/d.cnki.gcqgx.2024.001102.